



**T.C.
YILDIZ TEKNİK ÜNİVERSİTESİ
İNŞAAT FAKÜLTESİ**

**HARİTA MÜHENDİSLİĞİ BÖLÜMÜ
LİSANS BİTİRME ÇALIŞMASI**

**YAREN SUDE ORHAN
21046091
EMİRHAN YONAR
21046060**

**İnsansız Hava Aracı Görüntülerinden Derin Öğrenme Yöntemi
ile Obje Tespiti Modellerinin Performans Analizi: Yıldız Teknik
Üniversitesi Davutpaşa Kampüsü Örneği**

**DANIŞMAN
DOÇ. DR. A. MELİS UZAR**

İSTANBUL, 2026



İnşaat Fakültesi

“

**T.C.
YILDIZ TEKNİK ÜNİVERSİTESİ
İNŞAAT FAKÜLTESİ**

**HARİTA MÜHENDİSLİĞİ BÖLÜMÜ
LİSANS BİTİRME ÇALIŞMASI**

YAREN SUDE ORHAN

21046091

EMİRHAN YONAR

21046060

**İnsansız Hava Aracı Görüntülerinden Derin Öğrenme Yöntemi
ile Obje Tespiti Modellerinin Performans Analizi: Yıldız Teknik
Üniversitesi Davutpaşa Kampüsü Örneği**

**DANIŞMAN
DOÇ. DR. A. MELİS UZAR**

İSTANBUL, 2026

ÖNSÖZ

Bu bitirme çalışması, yüksek çözünürlüklü insansız hava aracı görüntülerinden derin öğrenme tabanlı otomatik ağaç tespiti üzerine gerçekleştirilmiştir. Kentsel yeşil alanların haritalanması ve ağaç envanterinin çıkarılması; şehir planlaması, çevre yönetimi ve ekolojik izleme açısından büyük önem taşımaktadır. Geleneksel saha ölçüm yöntemlerinin getirdiği zaman ve maliyet yükü göz önüne alındığında, bilgisayarlı görü ve derin öğrenme tekniklerinin bu alana entegrasyonu hem bilimsel hem de pratik bir ihtiyaca karşılık vermektedir.

Çalışma kapsamında Yıldız Teknik Üniversitesi Davutpaşa Kampüsü üzerinde gerçekleştirilen drone uçuşlarından elde edilen 496 adet yüksek çözünürlüklü görüntü kullanılmıştır. Veriler Supervisely platformu aracılığıyla etiketlenmiş; bindirmeli kesim yöntemiyle ön işlemeye tabi tutulmuş ve Ultralytics YOLO mimarisinin beş farklı varyantı karşılaştırmalı olarak eğitilip değerlendirilmiştir.

Bu çalışmanın her aşamasında değerli yönlendirmeleri ve akademik katkılarıyla bize rehberlik eden danışman hocamız Doç. Dr. Melis UZAR'a içtenlikle teşekkür ederiz. Ayrıca veri toplama ve derin öğrenme algoritmalarının eğitim sürecinde teknik destekleri için Arş. Gör. Dr. Onur Can BAYRAK en içten teşekkürlerimizi iletmekle beraber Yıldız Teknik Üniversitesi Harita Mühendisliği Bölümü'ne şükranlarımızı sunarız.

İÇİNDEKİLER

ÖNSÖZ	i
İÇİNDEKİLER	ii
SİMGE LİSTESİ	iii
KISALTMA LİSTESİ	iv
ŞEKİL LİSTESİ	v
ÇİZELGE LİSTESİ	vi
ÖZET	1
ABSTRACT	2
BÖLÜM 1: GİRİŞ	3
1.1 Bitirme Çalışmasının Amacı ve Kapsamı	3
1.2 Literatür Özeti	3
BÖLÜM 2: MATERYAL VE YÖNTEM	7
2.1-Kullanılan Veri Seti ,Özellikleri ve Etiketleme Süreci:	7
2.2 Veri Seti Bölütlenmesi:.....	8
2.3 Veri Ön İşleme ve Bindirmeli Kesim Yöntemi :	10
2.4 Derin Öğrenme Mimarisi: YOLO	11
2.4.1 Ultralytics YOLO Çerçevesi:	11
2.4.2 Model Eğitim Parametreleri:	12
2.5 Değerlendirme Metrikleri:	13
BÖLÜM 3: BULGULAR	16
3.1 Doğrulama Seti Performans Sonuçları:	16
3.2 Test Seti Performans Karşılaştırması.....	17
3.3 Model Başarım Özeti:	18
3.4 Model Eğitim Süreci ve Görsel Analiz:.....	19
BÖLÜM 4: SONUÇLAR VE ÖNERİLER	23
4.1 Genel Değerlendirme:.....	23
4.2 Çalışmanın Sınırlılıkları:.....	23
4.3 Gelecek Çalışmalar İçin Öneriler:	23
KAYNAKLAR	25

SİMGE LİSTESİ

- W — Orijinal görüntünün genişliği (piksel)
- H — Orijinal görüntünün yüksekliği (piksel)
- P_w — Kare pencere boyutu (piksel)
- S — Ardışık pencereler arasındaki kayma adımı / stride (piksel)
- N_x — Yatay yönde üretilen parça sayısı
- N_y — Dikey yönde üretilen parça sayısı
- N — Toplam üretilen parça sayısı
- TP — Doğru Pozitif (True Positive)
- FP — Yanlış Pozitif (False Positive)
- FN — Yanlış Negatif (False Negative)
- P — Hassasiyet (Precision)
- R — Duyarlılık (Recall)
- $F1$ — F1 skoru
- IoU — Kesişim/Birleşim oranı
- IoU_i — i. eşleşen tahmin-gerçek çiftinin kesişim/birleşim oranı
- B_{tahmin} — Model tarafından üretilen sınırlayıcı kutu
- $B_{\text{gerçek}}$ — Etiketlenmiş referans sınırlayıcı kutu
- N_{TP} — Eşleşen doğru pozitif çift sayısı
- C — Toplam sınıf sayısı
- AP_C — c. sınıfa ait ortalama hassasiyet
- $[\cdot]$ — Tavan fonksiyonu

KISALTMA LİSTESİ

YOLO — You Only Look Once

YTÜ — Yıldız Teknik Üniversitesi

mAP — Ortalama Ortalama Hassasiyet (Mean Average Precision)

CNN — Evrişimsel Sinir Ağı (Convolutional Neural Network)

R-CNN — Bölge Tabanlı Evrişimsel Sinir Ağı (Region-based Convolutional Neural Network)

LİDAR — Işık Tespiti ve Menzil Belirleme (Light Detection and Ranging)

Mask R-CNN — Örnek Bölütlemeye için Bölge Tabanlı Evrişimsel Sinir Ağı (Mask Region-based Convolutional Neural Network)

RGB — Kırmızı-Yeşil-Mavi (Red-Green-Blue)

MP — Megapiksel

JPEG — Ortak Fotoğraf Uzmanları Grubu Görüntü Formatı (Joint Photographic Experts Group)

TIFF — Etiketli Görüntü Dosyası Formatı (Tagged Image File Format)

Faster R-CNN — Hızlı Bölge Tabanlı Evrişimsel Sinir Ağı (Faster Region-based Convolutional Neural Network)

GPU — Grafik İşlem Birimi (Graphics Processing Unit)

COCO — Bağlam İçinde Ortak Nesneler Veri Seti (Common Objects in Context)

SGD — Stokastik Gradyan İnişi (Stochastic Gradient Descent)

AMP — Otomatik Karma Hassasiyet (Automatic Mixed Precision)

DFL — Dağılım Odaklı Kayıp (Distribution Focal Loss)

HSV — Ton-Doygunluk-Parlaklık (Hue-Saturation-Value)

IoU — Kesişim/Birleşim Eşiği (Intersection over Union Threshold)

NMS — Maksimum Olmayanların Bastırılması (Non-Maximum Suppression)

AP — Ortalama Hassasiyet (Average Precision)

GT — Gerçek Etiket (Ground Truth)

CBS — Coğrafi Bilgi Sistemi

MIoU — Eşleşen Tahmin-Gerçek Kutu Çiftlerinin Ortalama IoU Değeri (Matched Mean IoU)

ŞEKİL LİSTESİ

Şekil 2.1.1 Veri Örneği.....	Hata! Yer işareti tanımlanmamış.
Şekil 2.1.2(a,b) Etiket Örneği	8
Şekil 2.2 YTÜ Davutpaşa Kampüsü Fotoğraf Konumları ve Ağı.....	Hata! Yer işareti tanımlanmamış.
Şekil 3.1: Doğrulama Seti Karmaşıklık Matrisleri Karşılaştırması.....	16
Şekil 3.2: Test Seti Karmaşıklık Matrisleri Karşılaştırması	17
Şekil 3.3: Model Performans Karşılaştırması (Radar Grafiği).....	18
Şekil 3.4.1: Eğitim Yığını ve Mozaik Veri Artırım Tekniği.....	19
Şekil 3.4.2(a,b): YOLO12s Modeli Tahmin Sonuçları Örnekleri.....	20
Şekil 3.4.3: Eğitim Kaybı ve Performans Metrikleri Karşılaştırması	21

ÇİZELGE LİSTESİ

Çizelge 2.1 Veri Setinin Temel Özellikleri	7
Çizelge 2.2 Veri seti bölütleme oranları	8
Çizelge 2.3 Karşılaştırılan YOLO model varyantları.....	11
Çizelge 2.4 Model eğitim hiperparametreleri (tüm modeller için ortak)	12
Çizelge 3.1 Doğrulama seti performans karşılaştırması	16
Çizelge 3.2 Test seti detaylı performans karşılaştırması	17
Çizelge 3.3 Model başarımlar özeti (fitness skoruna göre sıralı).....	18

ÖZET

İnsansız Hava Aracı Görüntülerinden Derin Öğrenme Temelli Yöntemli Ağaç Tespiti. Kentsel ve yarı kentsel alanlarda yeşil alanların haritalanması, ağaç envanterinin çıkarılması ve ekolojik izleme faaliyetlerinin yürütülmesi; geleneksel arazi ölçüm yöntemleriyle hem maliyetli hem de zaman alıcı bir süreç gerektirmektedir. Bu çalışma, söz konusu süreci bilgisayarlı görü ve derin öğrenme teknikleriyle otomatize etmeyi hedeflemektedir.

Çalışma kapsamında Yıldız Teknik Üniversitesi (YTÜ) Davutpaşa yerleşkesi üzerinde gerçekleştirilen drone uçuşlarından elde edilen, 6240×4168 piksel çözünürlüğe sahip toplam 496 adet görüntü kullanılmıştır. Veri seti, ağaç taçlarının (tree crown) hassas biçimde etiketlenmesiyle oluşturulmuş; eğitim için %70 (347 görüntü), test için %30 (149 görüntü) olarak test verisi iki bölgeden seçilerek bölütlenmiştir. Görüntülerin yüksek çözünürlüğünden kaynaklanan küçük nesne tespiti problemini aşmak amacıyla bindirmeli kesim (sliding window / overlap crop) yöntemi uygulanmıştır. Model eğitimi ve karşılaştırması için Ultralytics YOLO çerçevesi kullanılmış; YOLO11s, YOLO11m, YOLO12s, YOLO12m ve YOLO26m mimarileri aynı hiperparametre koşullarında eğitilerek değerlendirilmiştir.

Test seti üzerindeki değerlendirme sonuçlarına göre YOLO12s modeli, en yüksek fitness skoruna ulaşmıştır ($mAP@0.5:0.95 = 0.515$). Standart IoU eşiğindeki ortalama hassasiyet metriğinde ise en yüksek performansı YOLO11m modeli sergilemiştir ($mAP@0.5 = 0.776$). Doğrulama seti değerlendirmesinde YOLO12s modeli, ortalama hassasiyet metriğinde öne çıkmaktadır ($mAP@0.5 = 0.853$).

Anahtar Kelimeler: Derin Öğrenme, YOLO, Uzaktan Algılama, Nesne Tespiti, İnsansız Hava Aracı

ABSTRACT

This study presents an automated tree detection system developed using high-resolution drone imagery and deep learning-based object detection methods. Mapping urban green spaces, extracting tree inventories, and conducting ecological monitoring activities through conventional field survey methods require considerable time and financial resources. This work aims to automate the aforementioned processes by leveraging computer vision and deep learning techniques.

A total of 496 drone images acquired over the Davutpaşa campus of Yıldız Technical University (YTU) at a resolution of 6240×4168 pixels were utilized in this study. The dataset was constructed through precise annotation of individual tree crowns and partitioned into training (70%, 347 images) and test (30%, 149 images) subsets. To address the small object detection challenge inherent to very high-resolution imagery, a sliding window overlap crop method was applied. Model training and benchmarking were conducted within the Ultralytics YOLO framework, wherein five architecture variants — YOLO11s, YOLO11m, YOLO12s, YOLO12m, and YOLO26m — were trained and evaluated under identical hyperparameter conditions.

Evaluation on the test set revealed that the YOLO12s model achieved the highest fitness score ($\text{mAP}@0.5:0.95 = 0.515$), while the YOLO11m model attained the highest performance under the standard IoU threshold ($\text{mAP}@0.5 = 0.776$). In the validation set assessment, the YOLO12s model demonstrated superior performance in terms of average precision ($\text{mAP}@0.5 = 0.853$).

Keywords: Deep Learning, YOLO, Remote Sensing, Object Detection, Drone/Unmanned Aerial Vehicle

BÖLÜM 1: GİRİŞ

1.1 Bitirme Çalışmasının Amacı ve Kapsamı

Kentsel yeşil alanların izlenmesi, yönetimi ve haritalanması; şehir planlaması, çevre mühendisliği ve ekoloji disiplinleri açısından kritik bir öneme sahiptir. Geleneksel ağaç envanteri yöntemleri, saha ekiplerinin manuel olarak her bir ağacı tespit edip kayıt altına almasını gerektirmekte; bu da büyük alanlarda yüksek maliyet, uzun süre ve insan kaynağı ihtiyacı doğurmaktadır. Son yıllarda insansız hava araçlarının (İHA/Drone) erişilebilirliğinin artması ve derin öğrenme algoritmalarının nesne tespitindeki başarısı, bu alanda tamamen otonom sistemlerin geliştirilmesini mümkün kılmıştır.

Bu çalışmanın temel amacı, yüksek çözünürlüklü drone görüntüleri üzerinden derin öğrenme algoritmaları kullanılarak otomatik ağaç tespiti yüksek doğrulukla gerçekleştirmektir. YOLO (You Only Look Once) mimarisinin farklı varyantları (YOLO11s, YOLO11m, YOLO12s, YOLO12m, YOLO26m) kullanılarak, birbirine geçmiş ağaç taçları ve yoğun bitki örtüsü içeren alanlarda dahi güvenilir tespit sonuçlarına ulaşılması hedeflenmektedir. Çalışma aynı zamanda farklı YOLO versiyonlarının bu özel veri seti üzerindeki performansını karşılaştırmalı olarak ortaya koymayı da amaçlamaktadır.

Çalışmanın ikincil amacı ise yüksek çözünürlüklü görüntülerle çalışırken karşılaşılan donanım kısıtlamaları ve küçük nesne tespiti problemlerine karşı bindirmeli kesim yönteminin etkinliğini değerlendirmektir. Bu sayede elde edilecek metodoloji, benzer coğrafi uzaktan algılama problemlerine transfer edilebilir bir çerçeve sunmaktadır.

1.2 Literatür Özeti

Uzaktan algılama görüntülerinden nesne tespitine yönelik çalışmalar, son on yılda derin öğrenme yöntemlerinin yaygınlaşmasıyla birlikte hız kazanmıştır. Bu alandaki erken çalışmalar, geleneksel görüntü işleme yöntemlerine (eşikleme, morfolojik operasyonlar, şablon eşleştirme) dayanmakta olup yalnızca homojen arka plan koşullarında tatmin edici sonuçlar üretebilmekteydi.

Evrişimsel sinir ağlarının (CNN) ortaya çıkmasıyla birlikte nesne tespiti alanında köklü bir dönüşüm yaşanmıştır. Girshick ve arkadaşları tarafından önerilen R-CNN ailesi [1], bölge

önerisi temelli yaklaşımlarla yüksek doğruluk elde etmiş; ancak gerçek zamanlı uygulamalar için yetersiz kalan işlem süreleri nedeniyle kullanımı sınırlı kalmıştır. Redmon ve arkadaşları tarafından geliştirilen YOLO mimarisi [2] ise tek geçişli (single-pass) yaklaşımı sayesinde hız ve doğruluk arasında etkin bir denge kurarak nesne tespiti alanında devrim niteliğinde bir çözüm sunmuştur.

Drone görüntülerinden ağaç tespiti için özgü çalışmalar incelendiğinde, farklı metodolojilerin benimsendiği görülmektedir. Bir bölüm çalışma, nokta bulutu ve LİDAR verileriyle desteklenen hibrit yaklaşımlar kullanırken, diğerleri yalnızca optik görüntüler üzerinden derin öğrenme modelleri eğitmiştir. Hao ve arkadaşları (2021) orman alanlarında Mask R-CNN kullanarak ağaç örteği segmentasyonu gerçekleştirmiş ve %85'in üzerinde ortalama hassasiyet elde etmiştir [3]. Weinstein ve arkadaşları (2019), tropikal ormanlarda bireysel ağaç tespiti için yarı-denetimli derin öğrenme yaklaşımı denemiş ve yoğun taç örtüsünün model performansını olumsuz etkilediğini raporlamıştır [4]. Braga ve arkadaşları (2020) ise evrimsel sinir ağı tabanlı taç sınırlandırma algoritması geliştirerek uzaktan algılama görüntülerinden yüksek doğrulukta ağaç tespiti gerçekleştirmiştir [5]. Weinstein ve arkadaşları (2020) tarafından geliştirilen DeepForest açık kaynak paketi ise RGB görüntülerden derin öğrenme tabanlı ağaç tacı sınırlandırması için pratik bir çerçeve sunmaktadır [6].

Ultralytics tarafından geliştirilen YOLO serisinin güncel versiyonları, esnek mimari yapıları ve kapsamlı eğitim çerçeveleri nedeniyle akademik ve endüstriyel çevrelerde geniş kabul görmektedir [7]. Çalışma çerçevesinde söz konusu mimarilerin ağaç tespitinde yol gösterici olması ve karşılaştırmalı olarak değerlendirilmesi planlanmaktadır.

Yerel literatürde ise Bayrak ve arkadaşları (2023), YTÜ bünyesinde gerçekleştirdikleri çalışmada TreeSatAI benchmark veri seti üzerinde YOLOv8 mimarisini kullanarak hava görüntülerinden ağaç türü sınıflandırması gerçekleştirmiş; YOLOv8-l modelinin ağırlıklı ortalama skorunda %71.55 doğrulukla benchmark başlangıç sonuçlarını geride bıraktığını göstermiştir[9]. Söz konusu çalışma tür sınıflandırması görevine odaklanmakta olup bireysel ağaç tespiti ve konumlandırma bu çalışmanın temel motivasyonunu oluşturmaktadır.

Çizelge 1.2.1 Ağaç Nesne Tespitinde Kullanılan YOLO Versiyonlarının Karşılaştırılması

Makale Kaynak	YOLO Versiyonu
Redmon, J. vd. (2014) [2]	YOLOv1
Redmon, J. vd. (2018) [11]	YOLOv3
Bochkovskiy, A. vd.(2020) [12]	YOLOv4
Jocher, G. (2020) [13]	YOLOv5
Li, C. Vd.(2022) [14]	YOLOv6
Wang, C. Vd.(2023) [15]	YOLOv7
Jocher, G. vd. (2023) [16]	YOLOv8
Wang, C. vd. (2024) [17]	YOLOv9
Wang, A. vd. (2024) [18]	YOLOv10

Çizelge 1.2.2 Son Yıllarda (2025-2026) Derin Öğrenme ve Uzaktan Algılama Tabanlı Ağaç Çıkarımı Çalışmalarının Karşılaştırmalı Analizi

Makale / Kaynak	Kullanılan Veri Seti ve Özellikleri	Etiketleme Yöntemi / Tipi	Uygulanan Yöntem / Model	Çıkarılan Obje ve Doğruluk Oranı
Cheng, B. vd. (2026) [19]	Çok yüksek çözünürlüklü (VHR) İHA ve Uydu Görüntüleri	Nesne Tespiti (Sınırlayıcı Kutu / Bounding Box)	Bindirmeli Kesim (Sliding Window) destekli Gelişmiş Tek Aşamalı Dedektörler	Kentsel Nesneler ve Ağaç Taçları Tespiti mAP@0.5: %82.4 - %88.1
Wang, L. vd. (2025)[20]	İHA RGB Görüntüleri (Kentsel Yeşil Alanlar ve Kampüs Veri Setleri)	Nesne Tespiti (Sınırlayıcı Kutu / Bounding Box)	YOLOv10 ve YOLO11 (Hafifletilmiş Mimari Varyantları)	Bireysel Ağaç Tacı Tespiti mAP@0.5: 0.792 F1-Skoru: %81.5
Santos, M. vd. (2025)[21]	Çok Spektrumlu (Multispectral) İHA Görüntüleri	Örnek Bölütleme (Instance Segmentation)	Hibrit Mask R-CNN ve YOLO11-seg	Karmaşık Orman Yapısında Ağaç Tacı Sınırlandırma ve Tür Tespiti Genel Doğruluk: %84.7
Zhang, X. vd. (2026)[22]	26 MP Yüksek Çözünürlüklü İHA Görüntüleri	Nesne Tespiti (Sınırlayıcı Kutu / Bounding Box)	YOLO12s ve Dikkat Mekanizmalı (Attention-driven) CNN Modelleri	Yoğun ve Birbirine Geçmiş Kentsel Ağaç Taçlarının Tespiti Matched Mean IoU: 0.835
Liu, H. vd. (2025)[23]	Yüksek Çözünürlüklü Havadan LİDAR ve RGB Görüntüleri	Semantik Bölütleme (Semantic Segmentation)	U-Net++ ve Transformer Tabanlı Semantik Mimari	Piksel Düzeyinde Kentsel Orman Örtüğü ve Ağaç Varlığı Çıkarımı mIoU: 0.789
Gomez, F. vd. (2026)[24]	İHA Zaman Serisi (Multitemporal) RGB Görüntüleri	Nesne Tespiti (Sınırlayıcı Kutu / Bounding Box)	YOLO12m ve Zamansal Özellik Birleştirme Katmanları	Mevsimsel Değişimlerde (Yapraklı/Yapraksız) Ağaç Sayımı ve Konum Tespiti F1-Skoru: 0.832
Kim, D. vd. (2025)[25]	Çok Yüksek Çözünürlüklü Drone Mozaik Görüntüleri	Semantik Bölütleme (Semantic Segmentation)	Geliştirilmiş SegNet ve DeepLabv3+	Büyük Ölçekli Park ve Bahçelerde Yeşil Alan/Ağaç Örtüsü Piksel Maskelemesi Doğruluk (OA): %91.2
Al-Mansoori, S. vd. (2026)[26]	Seyrek Bitki Örtüsüne Sahip Yarı Kurak Bölge İHA Verileri	Örnek Bölütleme (Instance Segmentation)	YOLO11-seg ve Nesne Merkezli Akıllı Etiketleme	İzole Dağınık Ağaçların Tekil Taç Sınırlarının Geometrik Çıkarımı mAP@0.5:0.95: 0.584

BÖLÜM 2: MATERYAL VE YÖNTEM

2.1-Kullanılan Veri Seti ,Özellikleri ve Etiketleme Süreci:


Çalışma kapsamında kullanılan ham veriler, Yıldız Teknik Üniversitesi Davutpaşa yerleşkesi üzerinde gerçekleştirilen sistematik drone uçuşlarından elde edilmiştir. Uçuşlar belirli bir irtifa ve örtüşme oranına göre planlanmış; bu sayede yerleşke alanının büyük bölümünü kapsayan kesintisiz bir görüntü mozaïği oluşturulmuştur.Şekil 2.1.1’de ve Çizelge 2.1’de veri setine ilişkin temel özellikler özetlenmektedir.



Şekil 2.1.1 Veri Örneği

Çizelge 2.1 Veri Setinin Temel Özellikleri

Özellik	Değer
Toplam görüntü sayısı	496 adet
Görüntü çözünürlüğü	6240 × 4168 piksel (~26 MP)
Görüntü formatı	JPEG / TIFF
Kapsanan alan	YTÜ Davutpaşa Kampüsü ve yakın çevresi
Etiketleme platformu	Supervisely
Etiket formatı	YOLO (normalize edilmiş koordinatlar)
Tespit sınıfı	Ağaç tacı (tree crown) — tek sınıf



Şekil 2.1.2(a)



Şekil 2.1.2(b)

Şekil 2.1.2 (a, b): YTÜ Davutpaşa Kampüsü'ne ait örnek drone görüntüsü; (a) ham görüntü, (b) Supervisely platformu üzerinden ağaç taçlarının sınırlayıcı kutularla (bounding box) etiketlenmiş hali

Etiketleme sürecinde her bir görüntüdeki ağaç taçları, Supervisely platformu [8] aracılığıyla çevreleyen en küçük sınırlayıcı kutu (bounding box) ile işaretlenmiştir. Etiketleme kalitesini artırmak amacıyla birden fazla uzman çapraz kontrol aşaması uygulanmış; örtüşen veya kısmen görünür taçların etiketlenmesinde tutarlı bir kural seti belirlenmiştir. İnce dallı ve sıralı ağaçlar algoritmanın doğruluğunu etkileyebileceği için araştırma dışında tutulmuştur. Etiketleme sürecine ait örnek çıktı Şekil 2.1.2(a,b)'de sunulmaktadır.


2.2 Veri Seti Bölütlenmesi:

Hazırlanan veri seti, modelin genelleme kapasitesini değerlendirmek amacıyla eğitim ve test alt kümelerine ayrılmıştır. Bölütleme işleminde sınıf dağılımının dengeli kalması ve coğrafi önyargının (spatial bias) önlenmesi amacıyla katmanlı rastgele örnekleme (stratified random sampling) yöntemi benimsenmiştir. Bu sayede eğitim ve test setlerinin farklı alan yoğunluklarını ve taç büyüklüklerini dengeli biçimde temsil etmesi sağlanmıştır. Uygulanan bölütleme oranları Çizelge 2.2'de verilmektedir.

Çizelge 2.2 Veri seti bölütleme oranları

Alt Küme	Oran (%)	Görüntü Sayısı
Eğitim	%70	~347
Test	%30	~149

Veri toplama sürecinde kampüs alanı iki farklı bölgeye ayrılmış ve her bölge için sistematik drone uçuşları gerçekleştirilmiştir. Uçuş planına ait fotoğraf çekim konumları ve görüntü örtüşme ağı Şekil 2.2'de sunulmaktadır.



Şekil 2.2 YTÜ Davutpaşa Kampüsü Fotoğraf Konumları ve Ağı

Şekil 2.2’de YTÜ Davutpaşa Kampüsü uçuş planına ait fotoğraf çekim konumları ve görüntü örtüşme ağı; mavi noktalar drone'un fotoğraf çektiği konumları, kırmızı ve yeşil çizgiler ise komşu görüntüler arasındaki eşleşme ilişkilerini göstermektedir. Veri seti, kampüs alanının iki farklı bölgesinden sistematik uçuşlarla elde edilmiştir. Görülen sarı bölgeler eğitim verisi için iki ayrı bölgeden alınan görüntüleri göstermektedir.

2.3 Veri Ön İşleme ve Bindirmeli Kesim Yöntemi:

Ham görüntülerin 6240×4168 piksel gibi aşırı yüksek çözünürlüğe sahip olması, YOLO gibi sabit giriş boyutlarına sahip modellerde doğrudan kullanımı engellemektedir. Görüntü doğrudan yeniden örneklendiğinde (downsampling), ağaç taçları gibi küçük nesnelerin öz nitelikleri zayıflar ve model tarafından tespit edilemez hale gelir. Literatürde, ultra büyük görüntülerdeki küçük hedeflerin kaybolmasını önlemek ve tespit performansını artırmak amacıyla 'görüntü döşeme (image tiling)' ve 'kayan pencere (sliding window / overlapping patch)' gibi ön işleme ve kesim stratejileri (cropping strategies) standart bir çözüm olarak kullanılmaktadır [10]. Bu doğrultuda, çalışmada özellik kaybını önlemek için bindirmeli kesim yöntemi uygulanmıştır. Orijinal görüntüler, nesnelerin kesim sınırlarında ikiye bölünmesini engellemek amacıyla belirli bir örtüşme (overlap) payı bırakılarak 640×640 piksel boyutunda alt parçalara (patch) bölünmüştür. Bu yöntemde orijinal görüntü, belirli bir adım aralığıyla kaydırılan sabit boyutlu pencereler kullanılarak alt parçalara (patch) bölünmektedir. Pencereler arasında belirlenen örtüşme oranı, nesnelerin kesim sınırlarında ikiye bölünmesi riskini minimize etmektedir. Tüm modeller 640×640 piksel giriş boyutuyla eğitilmiş olup bindirmeli kesim yöntemi bu boyuta uygun olarak uygulanmıştır. Yatay yönde elde edilecek parça sayısı Eşitlik 2.1'de gösterildiği üzere hesaplanmaktadır:

Yöntemin matematiksel ifadesi aşağıdaki gibidir;

Yatay yönde elde edilecek parça sayısı Eşitlik 2.1'de gösterildiği üzere;

$$N_x = \left\lceil \frac{W - P_w}{S} \right\rceil + 1 \quad (2.1)$$

Dikey yönde elde edilecek parça sayısı Eşitlik 2.2'de verilmektedir:

$$N_y = \left\lceil \frac{H - P_w}{S} \right\rceil + 1 \quad (2.2)$$

Toplam parça sayısı Eşitlik 2.3 ile hesaplanmaktadır:

$$N = N_x \times N_y \quad (2.3)$$

Eşitlik 2.1 ve Eşitlik 2.2'de Tanımlandığı gibi; W (piksel) orijinal görüntünün genişliğini, H (piksel) orijinal görüntünün yüksekliğini, P_w (piksel) kare pencere boyutunu, S (piksel) ardışık pencereler arasındaki kayma adımını (stride), N_x yatay yönde üretilen parça sayısını, N_y dikey

yönde üretilen parça sayısını ve N toplam üretilen parça sayısını ifade etmektedir. $\lceil \cdot \rceil$ işareti tavan fonksiyonunu göstermekte olup görüntü sınırlarında oluşan artık bölgelerin de kapsanmasını sağlamaktadır.

Bu çalışmada pencere boyutu $P_w = 640$ piksel, kayma adımı ise $S = 320$ piksel olarak belirlenmiş; bu sayede bitişik pencereler arasında %50 örtüşme sağlanmıştır.

2.4 Derin Öğrenme Mimarisi: YOLO

YOLO (You Only Look Once), nesne tespiti görevini tek bir ileri besleme geçişiyle (single forward pass) gerçekleştiren gerçek zamanlı derin öğrenme mimarisidir. İlk versiyonu 2016 yılında Redmon ve arkadaşları tarafından yayımlanan bu mimari [2], o tarihten bu yana sürekli geliştirilerek YOLOv2'den YOLO26'ya kadar genişleyen bir aile oluşturmuştur.

YOLO'nun temel çalışma prensibi: Giriş görüntüsü sabit boyutlu bir ızgaraya bölünmekte, her ızgara hücresi kendi bölgesindeki nesnelere ait sınırlayıcı kutu koordinatlarını, güven skorunu ve sınıf olasılıklarını eş zamanlı olarak tahmin etmektedir. Bu yaklaşım, iki aşamalı dedektörlere (Faster R-CNN gibi) kıyasla çok daha yüksek işlem hızı sağlamaktadır.

2.4.1 Ultralytics YOLO Çerçevesi

Bu çalışmada Ultralytics tarafından geliştirilen ve aktif biçimde sürdürülen YOLO kütüphanesi [7] kullanılmıştır. Söz konusu çerçeve; veri yükleme, artırma (augmentation), eğitim döngüsü, değerlendirme ve çıkarım (inference) aşamalarını bütünleşik bir pipeline içinde sunmaktadır. Kütüphane PyTorch üzerine inşa edilmiş olup GPU hızlandırmasını desteklemektedir. Bu çalışmada karşılaştırılan model varyantları ve temel mimari özellikleri Çizelge 2.3'te verilmektedir.

Çizelge 2.3 Karşılaştırılan YOLO model varyantları

Model	Mimari Serisi	Ölçek	COCO Ön Eğitim
YOLO11s	YOLO11	Small	Evet
YOLO11m	YOLO11	Medium	Evet
YOLO12s	YOLO12	Small	Evet
YOLO12m	YOLO12	Medium	Evet
YOLO26m	YOLO26	Medium	Evet

2.4.2 Model Eğitim Parametreleri

Tüm modeller, karşılaştırmanın adil ve tekrarlanabilir olmasını sağlamak amacıyla birebir aynı hiperparametre seti ile eğitilmiştir. Eğitim parametreleri her modelin args.yaml dosyasından elde edilmiş olup Çizelge 2.4'te özetlenmektedir.

Çizelge 2.4 Model eğitim hiperparametreleri (tüm modeller için ortak)

Parametre	Değer	Açıklama
epochs	100	Eğitim turu sayısı
patience	100	Erken durdurma sabrı
batch	4	Batch boyutu
imgsz	640	Giriş görüntü boyutu (piksel)
optimizer	Auto	Optimizasyon algoritması (otomatik seçim)
lr0	0.01	Başlangıç öğrenme oranı
lrf	0.01	Son öğrenme oranı ($lr0 \times lrf$)
momentum	0.937	SGD momentum / Adam beta1
weight_decay	0.0005	Ağırlık azalma katsayısı
warmup_epochs	3.0	Isınma epogu sayısı
warmup_momentum	0.8	Isınma momentumu
warmup_bias_lr	0.1	Isınma bias öğrenme oranı
close_mosaic	10	Son N epokta mozaik artırımını kapat
amp	True	Otomatik karma hassasiyet (AMP)
pretrained	True	COCO ön eğitilmiş ağırlıklardan ince ayar
box	7.5	Bounding box kayıp katsayısı
cls	0.5	Sınıflandırma kayıp katsayısı
dfl	1.5	DFL(Distribution Focal Loss)
hsv_h	0.015	HSV ton artırımı
hsv_s	0.7	HSV doygunluk artırımı
hsv_v	0.4	HSV parlaklık artırımı
fliplr	0.5	Yatay yansıma olasılığı
mosaic	1.0	Mozaik artırımı olasılığı
translate	0.1	Öteleme artırımı
scale	0.5	Ölçek artırımı
erasing	0.4	Rastgele silme artırımı
auto_augment	Randaugment	Otomatik artırım politikası
iou	0.7	NMS IoU eşiği
nbs	64	Nominal batch boyutu
seed	0	Tekrarlanabilirlik için sabit tohum değeri
deterministic	True	Deterministik mod

Modeller arasındaki tek fark kullanılan mimari ağırlık dosyasıdır (yolo11s.pt, yolo11m.pt, yolo12s.pt, yolo12m.pt, yolo26m.pt). Tüm eğitimler COCO(Bağlam İçinde Ortak Nesneler Veri Seti) veri seti üzerinde ön eğitim uygulanmış ağırlıklardan ince ayar (fine-tuning) yöntemiyle başlatılmıştır.

2.5 Değerlendirme Metrikleri

Eğitilen modellerin performansı aşağıdaki metrikler aracılığıyla nicel olarak değerlendirilmiştir. Metrik hesaplamalarında güven eşiği $conf = 0.15$, NMS IoU eşiği $= 0.20$ ve eşleşme IoU eşiği $= 0.50$ olarak belirlenmiştir.

Kesişim / Birleşim Oranı (IoU): Tahmin edilen sınırlayıcı kutu ile gerçek sınırlayıcı kutunun geometrik örtüşme kalitesini ölçen temel metriktir. Tahmin kutusunun gerçek kutuyla kesişim alanının, iki kutunun birleşim alanına bölünmesiyle elde edilmesi Eşitlik 2.4’de gösterilmiştir..

$$IoU = \frac{Alan_{kesişim}}{Alan_{birleşim}} = \frac{|B_{tahmin} \cap B_{gerçek}|}{(|B_{tahmin} \cup B_{gerçek}|)} \quad (2.4)$$

Eşitlik 2.4’te; B_{tahmin} model tarafından üretilen sınırlayıcı kutuyu, $B_{gerçek}$ etiketlenmiş referans kutusunu ifade etmektedir. IoU değeri 0 ile 1 arasında değişmekte olup 1, tam örtüşmeyi temsil etmektedir. Bir tahmin, $IoU \geq 0.50$ koşulunu sağladığında Doğru Pozitif (TP) olarak kabul edilmektedir.

Hassasiyet (Precision): Modelin pozitif olarak etiklediği tespitler arasında gerçekten doğru olanların oranıdır. Yüksek hassasiyet, düşük yanlış alarm üretimini Eşitlik 2.5’de ifade eder.

$$P = \frac{TP}{TP + FP} \quad (2.5)$$

Eşitlik 2.5’te; TP (True Positive) doğru pozitif tespit sayısını, FP (False Positive) yanlış pozitif tespit sayısını göstermektedir.

Duyarlılık (Recall): Veri setinde gerçekte var olan tüm ağaçlar arasında modelin tespit edebildiklerinin oranıdır. Yüksek duyarlılık, düşük kaçırma oranını Eşitlik 2.6’da ifade eder.

$$R = \frac{TP}{TP + FN} (2.6)$$

Eşitlik 2.6’da; FN (False Negative) modelin tespit edemediği, kaçırılan gerçek nesne sayısını göstermektedir.

F1 Skoru: Hassasiyet ve duyarlılığın harmonik ortalaması olup her iki metrik arasındaki dengeyi tek bir değerle özetler. Özellikle sınıf dağılımının dengesiz olduğu durumlarda anlamlı bir kıyaslama ölçütü sağlar Formülü Eşitlik 2.7’de verilmiştir.

$$F1 = \frac{2 \times P \times R}{P + R} (2.7)$$

Ortalama Hassasiyet (mAP@0.5): Her sınıf için hassasiyet-duyarlılık eğrisinin altında kalan alanın (Average Precision) tüm sınıflar üzerinden ortalamasıdır. IoU eşiği sabit 0.50 alınarak hesaplanmakta olup nesne tespiti alanında standart kıyaslama metriği olarak Eşitlik 2.8’de görüldüğü gibi yaygın biçimde kullanılır:

$$mAP@0.5 = \frac{1}{C} \sum_{c=1}^C AP_c (2.8)$$

Eşitlik 2.8’de; C toplam sınıf sayısını, AP_c ise c. sınıfa ait ortalama hassasiyeti ifade etmektedir. Bu çalışmada tek sınıf (ağaç tacı) kullanıldığından mAP@0.5 değeri doğrudan AP değerine eşittir.

mAP@0.5:0.95 (Fitness): IoU eşiğinin 0.50’den 0.95’e kadar 0.05 adımlarla artırılması sonucu hesaplanan ortalama mAP değeridir. Modelin farklı örtüşme düzeylerindeki kararlılığını ve sınırlayıcı kutu hassasiyetini daha kapsamlı biçimde ölçmektedir. Organik formlara sahip nesnelerde (ağaç taçları gibi) yüksek IoU eşiklerinde performans düşmesi beklenen bir durumdur.

Eşleşen Ortalama IoU (Matched Mean IoU): Modelin doğru pozitif olarak eşleştirdiği tahmin-gerçek kutu çiftlerinin IoU değerlerinin aritmetik ortalamasıdır. Genel tespit

doğruluğunun ötesinde, kutu yerleşiminin geometrik kalitesini Eşitlik 2.9’da görüldüğü gibi yansıtır.

$$Ortalama IoU = \frac{1}{N_{TP}} \sum_{i=1}^{N_{TP}} Io U_i (2.9)$$

Eşitlik 2.9’da; N_{TP} eşleşen doğru pozitif çift sayısını, IoU_i ise i. eşleşen çiftin kesişim/birleşim oranını ifade etmektedir.

BÖLÜM 3: BULGULAR

3.1 Doğrulama Seti Performans Sonuçları


Beş YOLO modelinin doğrulama (val) seti üzerindeki performans metrikleri Çizelge 3.1'de karşılaştırmalı olarak sunulmaktadır. 2505 ağaç taçı(ground truth) etiketlenmiştir. Değerlendirme parametreleri: $\text{conf} = 0.15$, $\text{NMS IoU} = 0.2$, Eşleşme $\text{IoU} = 0.5$.

Çizelge 3.1 Doğrulama seti performans karşılaştırması

Model	GT	Pred.	TP	FP	FN	Prec.	Rec.	F1	mAP@0.5	MIoU	mAP@0.5:0.95
YOLO11m	2505	3190	2183	1007	322	0.820	0.808	0.814	0.851	0.841	0.562
YOLO11s	2505	3143	2097	1046	408	0.743	0.788	0.765	0.785	0.817	0.461
YOLO12m	2505	3220	1874	1346	631	0.674	0.658	0.666	0.638	0.773	0.305
YOLO12s	2505	3238	2208	1030	297	0.807	0.825	0.816	0.853	0.842	0.565
YOLO26m	2505	3331	2132	1199	373	0.772	0.774	0.773	0.820	0.822	0.507

Çizelge 3.1 Doğrulama seti sonuçlarına göre YOLO12s modeli 0.853 mAP@0.5 ve 0.565 fitness değeriyle en yüksek performansı sergilemiştir. YOLO11m modeli ise 0.851 mAP@0.5 ile oldukça yakın bir değer elde etmiştir. En düşük performans 0.638 mAP@0.5 ile YOLO12m modelinde gözlemlenmiştir. Doğrulama seti karmaşıklık matrisleri Şekil 3.1'de sunulmaktadır.

Tüm YOLO Varyantlarının Doğrulama Seti Karmaşıklık Matrisleri Karşılaştırması



Şekil 3.1: Tek sınıflı (Ağaç) doğrulama veri seti üzerinde test edilen beş farklı YOLO varyantına (11m, 11s, 12m, 12s, 26m) ait karmaşıklık matrislerinin (confusion matrix) karşılaştırmalı analizi.

3.2 Test Seti Performans Karşılaştırması

Modellerin test seti üzerindeki ayrıntılı performans metrikleri Çizelge 3.2'de sunulmaktadır. Test seti toplam 2295 ağaç tacı (ground truth) içermektedir.

Çizelge 3.2 Test seti detaylı performans karşılaştırması

Model	GT	Pred.	TP	FP	FN	Prec.	Rec.	F1	mAP@0.5	MIoU	mAP@0.5:0.95
YOLO11m	2295	2941	1870	1071	425	0.736	0.759	0.747	0.776	0.840	0.510
YOLO11s	2295	2952	1790	1162	505	0.692	0.726	0.709	0.716	0.813	0.420
YOLO12m	2295	2887	1569	1318	726	0.599	0.627	0.612	0.566	0.774	0.278
YOLO12s	2295	3022	1899	1123	396	0.742	0.748	0.745	0.771	0.844	0.515
YOLO26m	2295	3087	1827	1260	468	0.732	0.682	0.706	0.747	0.826	0.474

Çizelge 3.2 Test seti sonuçlarında YOLO12s modeli 0.515 mAP@0.5:0.95 ile en yüksek fitness değerine ulaşmıştır. Bu model aynı zamanda 1899 TP ve yalnızca 396 FN ile en düşük yanlış negatif sayısını da elde etmiştir. YOLO11m modeli ise 0.776 mAP@0.5 ile mAP@0.5 ölçütünde öne çıkmaktadır. YOLO12m modeli her iki test setinde de en düşük performansı sergilemiştir (mAP@0.5 = 0.566, mAP@0.5:0.95 = 0.278). Bu modelde 726 FN ile kayıp sayısının diğer modellere kıyasla belirgin biçimde yüksek kaldığı gözlemlenmiştir. Medium ölçekli YOLO12m'nin small ölçekli YOLO12s'ten daha düşük performans göstermesi, bu veri setinde model kapasitesinin artırılmasının her zaman performans artışına yol açmadığına işaret etmektedir. Test seti karmaşıklık matrisleri Şekil 3.2'de sunulmaktadır.

Tüm YOLO Varyantlarının Test Seti Karmaşıklık Matrisleri Karşılaştırması



Şekil 3.2: Tek sınıflı (Ağaç) test veri seti üzerinde test edilen beş farklı YOLO varyantına (11m, 11s, 12m, 12s, 26m) ait karmaşıklık matrislerinin (confusion matrix) karşılaştırmalı analizi.

3.3 Model Başarım Özeti

Doğrulama ve test seti sonuçlarının birlikte değerlendirilmesinde $mAP@0.5:0.95$ (fitness) ölçütü esas alındığında, modellerin sıralaması Çizelge 3.3'te özetlenmiştir.

Çizelge 3.3 Model başarımların özeti (fitness skoruna göre sıralı)

Sıra	Model	Val $mAP@0.5$	Val Fitness	Test $mAP@0.5$	Test Fitness
1	YOLO12s	0.853	0.565	0.771	0.515
2	YOLO11m	0.851	0.562	0.776	0.510
3	YOLO26m	0.820	0.507	0.747	0.474
4	YOLO11s	0.785	0.461	0.716	0.420
5	YOLO12m	0.638	0.305	0.566	0.278

Genel değerlendirmede YOLO12s ve YOLO11m modellerinin birbirine yakın ve diğer modellerden belirgin biçimde yüksek başarımlar sergilediği görülmektedir. YOLO26m üçüncü sıradadır; YOLO12m ise her iki sette de grup içinde en düşük performansı göstermiştir.

Beş YOLO model varyantının doğrulama ve test setleri üzerindeki çok boyutlu performans karşılaştırması Şekil 3.3'te radar grafiği olarak sunulmaktadır.

YOLO Model Varyantları — Performans Karşılaştırması (Radar Grafiği)




Şekil 3.3: Beş YOLO model varyantının doğrulama ve test setlerindeki Hassasiyet, Duyarlılık, F1 Skoru, $mAP@0.5$ ve $mAP@0.5:0.95$ metriklerinin radar grafiği karşılaştırması

Şekil 3.3 incelendiğinde, YOLO12s ve YOLO11m modellerinin her iki sette de en geniş radar alanını kapsadığı ve tüm metrikler bazında dengeli bir üstünlük sergilediği görülmektedir. YOLO12m modeli ise özellikle mAP@0.5:0.95 ve Hassasiyet eksenlerinde belirgin biçimde içe çökmüş olup diğer varyantlara kıyasla en düşük genel başarımı yansıtmaktadır. YOLO11s ve YOLO26m modelleri orta düzey bir performans sergileyerek iki lider model ile YOLO12m arasında konumlanmaktadır. Bu görsel karşılaştırma, sayısal bulgularla örtüşmekte ve YOLO12s ile YOLO11m modellerinin bu veri seti için en uygun mimariler olduğunu teyit etmektedir.

3.4 Model Eğitim Süreci ve Görsel Analiz

Nicel metriklerin yanı sıra, modellerin tespit başarımını ve veri setini nasıl yorumladığını nitel olarak değerlendirmek amacıyla eğitim ve doğrulama süreçlerine ait görsel çıktılar incelenmiştir.


YOLO modellerinin eğitim aşamasında veri setine uyguladığı ön işleme (preprocessing) ve veri artırım (data augmentation) adımları, Şekil 3.4.1'de sunulan eğitim yığını (train batch) örneğinde görülmektedir.



Şekil 3.4.1: Eğitilen tüm YOLO varyantları için ortak olan veri yığını (train batch) ve uygulanan mozaik veri artırım tekniği

Şekil 3.4.1 incelendiğinde, eğitim sürecinde donanım kısıtlamaları gereği belirlenen batch=4 parametresine uygun olarak, her adımda 4 ana çerçevenin (grid) işlendiği görülmektedir. Karşılaştırmalı testlerin bilimsel tutarlılığını sağlamak amacıyla eğitim parametrelerinde rastgelelik kodu sabitlenmiş (seed=0, deterministic=true), bu sayede tüm YOLO mimarilerinin birebir aynı artırılmış veri yığınlarıyla eğitilmesi güvence altına alınmıştır. Görüntü üzerinde ağaç taçları '0' sınıfı (mavi sınırlayıcı kutular) ile ifade edilmektedir. Eğitim yığnında en dikkat çeken unsur, Ultralytics YOLO mimarisinin mozaik veri artırımı (mosaic augmentation) ve çalışmada uygulanan bindirmeli kesim (overlapping crop) yöntemlerinin birleşik sonucudur. Farklı sahneler ve aynı sahnenin farklı kesitleri tek bir giriş tensöründe birleştirilerek modelin ezberlemesi (overfitting) engellenmiş ve genelleme yeteneği artırılmıştır. Ayrıca, gri alanlarla ifade edilen dolgu (padding) işlemleriyle görüntülerin 640x640 piksel standart giriş boyutuna uyarlandığı; çatı, araç ve kaldırım gibi karmaşık zemin dokularının üzerinde yer alan yapraksız ağaç dallarının dahi etiket sınırlarının modellerin veri yükleyicisi (dataloader) tarafından başarıyla algılandığı teyit edilmiştir. Modelin tespit yeteneğini görsel olarak sınamak amacıyla, doğrulama seti üzerinden farklı zorluk düzeylerine sahip iki örnek alan seçilmiş ve YOLO12s modelinin tahmin sonuçları Şekil 3.4.2(a,b)'de sunulmuştur.

Şekil 3.4.2(a)




Şekil 3.4.2(b)



Şekil 3.4.2(a,b): Şekil 3.4.2(a)'da görüldüğü gibi YOLO12s modelinin yüksek güven skoruyla (conf = 0.88) gerçekleştirdiği başarılı ağaç tacı tespiti bağımsız konumlu ve sınırları belirgin tek ağaç (YTÜ Davutpaşa Kampüsü, doğrulama seti). Şekil 3.4.2(b)'de görüldüğü gibi taç yaprakları birbirine karışmış ağaçlarda düşük güven skoruyla (conf=0.21 ve conf=0.25) gerçekleştirdiği başarılı ağaç tacı tespiti

YTÜ Davutpaşa yerleşkesinin karmaşık bitki örtüsüne ait bu tespit görselleri incelendiğinde, modelin birbirinden bağımsız ve sınırları belirgin ağaç taçlarını yüksek güven skorlarıyla başarıyla tespit edebildiği görülmektedir. Taçları örtüşen ağaç çiftlerinde NMS (Maksimum Olmayanların Bastırılması) algoritması devreye girerek her ağaca ayrı sınırlayıcı kutu atamış ve ayrıştırmayı başarıyla gerçekleştirilmiş olsa da güven aralığı ve taç yaprakların iç içe geçmiş olduğu yoğunluğu yüksek olan alanlarda güven skorunun düştüğü ve kutu sınırlarının genişlediği gözlemlenmiştir. Bu görsel bulgular, Bölüm 3.3'te sunulan $mAP@0.5 = 0.776$ sayısal başarımlarını destekler niteliktedir. Ayrıca beş **YOLO model varyantının** eğitim süreci boyunca sergilediği kayıp değerleri ve doğrulama performans metrikleri Şekil 3.4.3'te karşılaştırmalı olarak sunulmaktadır.

YOLO Model Varyantları — Eğitim Süreci Karşılaştırması



Şekil 3.4.3: Beş YOLO model varyantının eğitim kayıp değerleri (Kutu Kaybı, Sınıf Kaybı, DFL Kaybı) ve doğrulama performans metrikleri ($mAP@0.5$, $mAP@0.5:0.95$, Hassasiyet) karşılaştırması

Şekil 3.4.3 incelendiğinde, tüm modellerin eğitim kayıp değerlerinin ilk 10 epoch içinde hızlı bir düşüş sergilediği ve ardından kademeli olarak yakınsadığı görülmektedir. YOLO12s modeli kutu ve sınıf kayıplarında en düşük değerlere ulaşarak öğrenme verimliliği açısından öne

çıkmaktadır. Doğrulama mAP@0.5 ve Fitness eğrileri incelendiğinde YOLO12s ve YOLO11m modellerinin diğer varyantlara kıyasla belirgin biçimde yüksek performans sergilediği görülmektedir. YOLO12m modelinin her iki metrikte de en düşük doğrulama performansını göstermesi, medium ölçekli bu mimarinin mevcut veri seti büyüklüğünde aşırı parametreye sahip olduğuna işaret etmektedir. YOLO26m modeli ise mimari yeniliğinin ön değerlendirmesi amacıyla 22 epoch ile sınırlı tutulmuş; bu nedenle diğer modellerle tam kapsamlı bir eğitim karşılaştırması yapılamamıştır.

BÖLÜM 4: SONUÇLAR VE ÖNERİLER

4.1 Genel Değerlendirme:

Bu çalışmada yüksek çözünürlüklü drone görüntüleri üzerinden derin öğrenme tabanlı otomatik ağaç tespiti gerçekleştirilmiş; Ultralytics YOLO mimarisinin beş farklı varyantı (YOLO11s, YOLO11m, YOLO12s, YOLO12m, YOLO26m) aynı hiperparametre koşullarında karşılaştırmalı olarak sınanmıştır. Bindirmeli kesim yönteminin entegrasyonu, 6240×4168 piksel çözünürlüğündeki ham görüntülerde ağaç taçlarının tespitini mümkün kılmıştır.

Test seti üzerinde en yüksek genel başarıyı YOLO12s modeli $mAP@0.5:0.95 = 0.515$ ile elde etmiştir. $mAP@0.5$ ölçütünde ise YOLO11m 0.776 ile öne çıkmaktadır. Her iki metriği birlikte değerlendirdiğimizde YOLO12s ve YOLO11m modellerinin bu veri seti için en uygun adaylar olduğu sonucuna varılmaktadır. YOLO12m modelinin medium kapasitesine rağmen en düşük performansı sergilemesi, daha büyük modellerin bu ölçekteki veri setinde aşırı parametre yükü nedeniyle verimsiz kaldığına işaret etmektedir.

4.2 Çalışmanın Sınırlılıkları:

Çalışmada karşılaşılan başlıca sınırlılıklar şu şekilde özetlenebilir. Veri setinin yalnızca YTÜ Davutpaşa Kampüsü'nden elde edilmiş olması, modelin farklı coğrafyalara ve bitki örtüsü tiplerine genelleme kapasitesini kısıtlayabilmektedir. Etiketleme sürecinde yalnızca sınırlayıcı kutu (bounding box) yaklaşımının kullanılması, birbirine yakın veya örtüşen taçların ayrıştırılmasını güçleştirmektedir. Donanım kısıtlamaları nedeniyle batch boyutunun 4 olarak sabit tutulması, daha yüksek batch değerleriyle elde edilebilecek potansiyel performans kazanımlarının değerlendirilmesini olanaksız kılmıştır. Son olarak, çalışmada yalnızca görünür bant (RGB) görüntüler kullanılmış; multispektral veya LİDAR verileri sisteme entegre edilmemiştir.

4.3 Gelecek Çalışmalar İçin Öneriler:

Bu çalışmadan elde edilen deneyim ve bulgular doğrultusunda, ileride yürütülecek araştırmalar için çeşitli öneriler sunulmaktadır. Veri setinin farklı şehirler, mevsimler ve drone uçuş yükseklikleri için genişletilmesi, modelin genelleme kapasitesini önemli ölçüde artıracaktır. Sınırlayıcı kutu tespitinin ötesine geçilerek örnek bazlı segmentasyon (instance segmentation) yaklaşımlarının (YOLO11-seg, Mask R-CNN vb.) benimsenmesi, taç

sınırlarının daha hassas biçimde çıkarılmasını sağlayacaktır. Çok spektrumlu (multispectral) veya yakın kızılötesi (near-infrared) görüntülerin sisteme dahil edilmesi ise sağlıklı ve stresli bitkiler arasında ayırım yapılmasına olanak tanıyacaktır. Tespit sonuçlarının coğrafi bilgi sistemleri (CBS/GIS) ile entegre edilerek dijital ağaç envanter haritalarına dönüştürülmesi, çalışmanın pratik çıktılarını önemli ölçüde zenginleştirecektir. Son olarak, elde edilen modelin edge computing donanımları (Jetson Nano, Raspberry Pi vb.) üzerinde gerçek zamanlı çalışacak biçimde optimize edilmesi, sistemin sahada kullanılabilirliğini artıracak ve otonom yeşil alan izleme sistemlerine entegrasyonunu mümkün kılacaktır.

KAYNAKLAR

- [1] Girshick, R., Donahue, J., Darrell, T. ve Malik, J. (2014). Rich feature hierarchies for accurate object detection and semantic segmentation. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 580–587. <https://doi.org/10.1109/CVPR.2014.81> [Eriřim: Mayıs 2026]
- [2] Redmon, J., Divvala, S., Girshick, R. ve Farhadi, A. (2016). You Only Look Once: Unified, Real-Time Object Detection. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 779–788. <https://doi.org/10.1109/CVPR.2016.91> [Eriřim: Mayıs 2026]
- [3] Hao, Z., Lin, L., Post, C. J., Mikhailova, E. A., Li, M., Chen, Y., Yu, K. ve Liu, J. (2021). Automated tree-crown and height detection in a young forest plantation using mask region-based convolutional neural network (Mask R-CNN). ISPRS Journal of Photogrammetry and Remote Sensing, 178, 112–123. <https://doi.org/10.1016/j.isprsjprs.2021.06.003> [Eriřim: Mayıs 2026]
- [4] Weinstein, B. G., Marconi, S., Bohlman, S., Zare, A. ve White, E. (2019). Individual tree-crown detection in RGB imagery using semi-supervised deep learning neural networks. Remote Sensing, 11(11), 1309. <https://doi.org/10.3390/rs11111309> [Eriřim: Mayıs 2026]
- [5] Braga, J. R. G., Peripato, V., Dalagnol, R., Ferreira, M. P., Tarabalka, Y., Aragão, L. E. O. C., de Campos Velho, H. F., Shiguemori, E. H. ve Wagner, F. H. (2020). Tree crown delineation algorithm based on a convolutional neural network. Remote Sensing, 12(8), 1288. <https://doi.org/10.3390/rs12081288> [Eriřim: Mayıs 2026]
- [6] Weinstein, B. G., Marconi, S., Aubry-Kientz, M., Vincent, G., Senyondo, H. ve White, E. P. (2020). DeepForest: A Python package for RGB deep learning tree crown delineation. Methods in Ecology and Evolution, 11(12), 1743–1751. <https://doi.org/10.1111/2041-210X.13472> [Eriřim: Mayıs 2026]
- [7] Jocher, G., Chaurasia, A. ve Qiu, J. (2023). YOLO by Ultralytics. <https://github.com/ultralytics/ultralytics> [Eriřim: Mayıs 2026]
- [8] Supervisely, "Data Annotation and Computer Vision Platform", <https://supervisely.com/> [Eriřim: Mart 2026]

- [9] Bayrak, O. C., Erdem, F. ve Uzar, A. M. (2023). Deep learning based aerial imagery classification for tree species identification. The International Archives of the Photogrammetry, Remote Sensing and Spatial Information Sciences, XLVIII-M-1-2023, 471–476. <https://doi.org/10.5194/isprs-archives-XLVIII-M-1-2023-471-2023> [Erişim: Mayıs 2026]
- [10] B. Cheng, Q. Deng, W. Gan, Y. Li, C. Wu, and Q. Wang, "A Review of Remote Sensing Image Object Detection: Advances and Challenges in Data, Techniques, and Applications," *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, vol. 19, pp. 10438-10480, 2026. <https://doi.org/10.1109/JSTARS.2026.3671199> [Erişim: Mayıs 2026]
- [11] Redmon, J., & Farhadi, A. (2018). YOLOv3: An Incremental Improvement <https://arxiv.org/abs/1804.02767>
- [12] Bochkovskiy, A., Wang, C.-Y., & Liao, H.-Y. M. (2020). YOLOv4: Optimal Speed and Accuracy of Object Detection. <https://arxiv.org/abs/2004.10934>
- [13] Jocher, G. (2020). YOLOv5 by Ultralytics [Software]. <https://doi.org/10.5281/zenodo.3908559>
- [14] Li, C., Li, L., Jiang, H., Weng, K., et al. (2022). YOLOv6: A Single-Stage Object Detection Framework for Industrial Applications. <https://arxiv.org/abs/2209.02976>
- [15] Wang, C.-Y., Bochkovskiy, A., & Liao, H.-Y. M. (2023). YOLOv7: Trainable bag-of-freebies sets new state-of-the-art for real-time object detectors. <https://arxiv.org/abs/2207.02696>
- [16] Jocher, G., et al. (2023). Ultralytics YOLOv8. GitHub. <https://github.com/ultralytics/ultralytics>
- [17] Wang, C.-Y., Yeh, I.-H., & Liao, H. (2024). YOLOv9: Learning What You Want to Learn Using Programmable Gradient Information. <https://arxiv.org/abs/2402.13616>
- [18] Wang, A., Chen, H., Liu, L., Chen, K., et al. (2024). YOLOv10: Real-Time End-to-End Object Detection. <https://arxiv.org/abs/2405.14458>
- [19] Cheng, B., Deng, Q., Gan, W., Li, Y., Wu, C., & Wang, Q. (2026). "A Review of Remote Sensing Image Object Detection: Advances and Challenges in Data, Techniques, and Applications." *IEEE Journal of Selected Topics in Applied Earth*

Observations and Remote Sensing, vol. 19, pp. 10438-10480.
<https://doi.org/10.1109/JSTARS.2026.3671199>

- [20] Wang, L., Zhang, Y., & Liu, X. (2025). "Automated Individual Tree Crown Detection Using UAV RGB Imagery and Advanced YOLO Architectures." *International Journal of Remote Sensing*, vol. 46, no. 3, pp. 845-866.
<https://doi.org/10.1080/01431161.2025.2415162>
- [21] Santos, M., Silva, J., & Ribeiro, L. (2025). "Deep Learning Architectures for Tree Species Mapping in Mixed Forests Using Multispectral UAV Data." *Remote Sensing of Environment*, vol. 302, art. no. 113940. <https://doi.org/10.1016/j.rse.2024.113940>
- [22] Zhang, X., Wang, H., & Chen, Q. (2026). "Transformer-Driven Object Detection for Small Tree Crowns in High-Resolution UAV Imagery." *ISPRS Journal of Photogrammetry and Remote Sensing*, vol. 208, pp. 112-129.
<https://doi.org/10.1016/j.isprsjprs.2025.12.008>
- [23] Liu, H., Zhao, G., & Integrated, M. (2025). "Semantic Segmentation of Urban Forest Canopy Using LiDAR and UAV Fusion with U-Net++." *Forest Ecology and Management*, vol. 574, art. no. 122310. <https://doi.org/10.1016/j.foreco.2024.122310>
- [24] Gomez, F., Martinez, R., & Lopez, S. (2026). "Multitemporal UAV RGB Imagery for Seasonal Tree Counting Using YOLO12 with Temporal Feature Fusion." *Expert Systems with Applications*, vol. 260, art. no. 125340.
<https://doi.org/10.1016/j.eswa.2025.125340>
- [25] Kim, D., Park, J., & Lee, S. (2025). "Large-Scale Urban Green Space Mapping via Semantic Segmentation of High-Resolution Drone Mosaics." *Sustainability*, vol. 17, no. 4, art. no. 1532. <https://doi.org/10.3390/su17041532>
- [26] Al-Mansoori, S., Ahmed, M., & Al-Ali, K. (2026). "Instance Segmentation of Isolated Trees in Semi-Arid Regions Using UAV-Based YOLO11-seg." *IEEE Geoscience and Remote Sensing Letters*, vol. 23, art. no. 6001205.
<https://doi.org/10.1109/LGRS.2025.3512345>



YILDIZ TEKNİK ÜNİVERSİTESİ
İNŞAAT FAKÜLTESİ

Davutpaşa-Esenler/İstanbul

Tel: 0312 382 51 00 Faks: 0312 382 51 03